

Презентация дипломной работы


Дипломная работа по программе «Аналитик данных»

Игнатенко Кирилл
Группа: DA-91

2026 г.



Описание бизнес-задачи, стейкхолдеров отчёта




1

Описание бизнес-задачи

- **Бизнес-задача.** Разработать объективную методологию оценки реального влияния COVID-19 на смертность в Москве с учётом эволюции вируса и предложить коэффициенты опасности штаммов для планирования эпидемиологических мер.
- **Актуальность исследования.** Официальная статистика может занижать реальные потери. Избыточная смертность — объективный индикатор для прогнозирования нагрузки на систему здравоохранения и оценки эффективности мер.
- **Стейкхолдеры.** Департамент здравоохранения Москвы (насколько статистика отражает реальные потери), Роспотребнадзор (какие штаммы наиболее опасны), Минздрав РФ (можно ли использовать избыточную смертность как федеральный индикатор), научное сообщество (какие мутации критически влияют на опасность), производители вакцин (на какие мишени ориентироваться), население (насколько опасен текущий штамм).
- **Гипотезы.** Гипотеза 1: методологии V1 и V2 дают одинаковые результаты (тест Манна-Уитни). Гипотеза 2: смертность в COVID-период не отличается от доковидной (тест Манна-Уитни, greater). Гипотеза 3: CFR одинаков у всех штаммов (тест Крускала-Уоллиса). Гипотеза 4: мутации не влияют на смертность и трансмиссивность (корреляционный анализ). Гипотеза 5: официальные данные — линейный предиктор избыточной смертности (визуализация, корреляция Спирмена).

Описание данных и их предобработки



2

Описание данных и их предобработки

Данные. Первый — Росстат, ежемесячная смертность от всех причин в Москве за 2006-2022 годы. Второй — оперативный штаб Москвы, официальные данные по COVID-19 за 2020-2022 годы. Третий — NCBI GenBank, геном SARS-CoV-2 штамм Wuhan-Hu-1 (NC_045512.2).

Качество данных. данные Росстата полные за 2006-2019 годы, за 2020-2022 годы — также полные. Официальные данные по COVID-19 имеют пропуски за январь-февраль 2020 (первые случаи зафиксированы в марте). Геномные данные — эталонная последовательность, качество высокое.

Аномалии. При проверке нормальности распределения смертности за доковидные годы выявлены выбросы в июле (14340.0), августе (15016.0) и октябре (9350.0), которые превышали 3 межквартильных размаха. Также обнаружены отрицательные значения `calculated_death` в исходных данных (например, -189 в марте 2020, -1104 в апреле 2022), что указывает на методическую ошибку в первичном расчёте.




Описание данных и их предобработки

Зависимости. Графический анализ показывает сезонность смертности (пики в зимние месяцы, спады летом). Корреляция между официальными данными и избыточной смертностью составляет $r \approx 0.52$ (умеренная нелинейная связь). CFR значимо различается между штаммами ($p = 0.003$).

Преобразования и очистка. Добавлена численность населения Москвы по годам (от 10923000 в 2006 до 13015000 в 2022) на основе данных Росстата. Выбросы в доковидных данных (июль, август) заменены на медианные значения по соответствующим месяцам. Все показатели приведены к стандартизованному виду — на 100 тысяч населения. Отрицательные значения `calculated_death` исключены из анализа избыточной смертности (оставлены только положительные значения). Для расчёта избыточной смертности V2 рассчитана средняя помесечная смертность за весь доковидный период 2006-2019 с учётом численности населения каждого года. Геномные данные обработаны с помощью библиотеки Biopython: выполнен поиск стартовых кодонов ATG (найдено 725 вхождений) и открытых рамок считывания ORF длиной более 100 п.н. (найдено 269).



Описание проведенного исследования



3

Описание проведенного исследования

Алгоритмы и техники. Расчёт избыточной смертности двумя методами — V1 (вычитание средней смертности за 2015-2019) и V2 (вычитание средней смертности за 2006-2019 с учётом численности населения каждого года). Проверка нормальности распределения критерием Шапиро-Уилка. Выявление выбросов методом межквартильного размаха ($3 \times IQR$). Сравнение распределений U-тестом Манна-Уитни. Сравнение трёх и более групп H-тестом Крускала-Уоллиса. Оценка связи ранговым коэффициентом корреляции Спирмена. Построение линейной регрессии с LOO-кросс-валидацией. Анализ генома — поиск паттернов и открытых рамок считывания ORF с помощью Biopython.



Описание проведенного исследования

Обоснование выбора методов. Непараметрические критерии выбраны потому, что распределения показателей смертности не являются нормальными (критерий Шапиро-Уилка $p < 0.05$ для большинства месяцев в COVID-период). U-тест Манна-Уитни позволяет сравнивать две независимые выборки без предположения о нормальности. H-тест Крускала-Уоллиса — аналог ANOVA для непараметрических данных, подходит для сравнения CFR между пятью штаммами. Коэффициент Спирмена устойчив к выбросам и не требует линейной связи. LOO-кросс-валидация выбрана из-за малого объема данных (23 точки) — каждый месяц по очереди становится тестовым.

Система метрик. Избыточная смертность на 100 тыс. населения (абсолютный показатель влияния пандемии). `death_coef` — коэффициент смертности штамма относительно Hu-1. `spread_coef` — коэффициент распространения относительно Hu-1. `composite_danger` — интегральный показатель опасности (70% смертность + 30% распространение). CFR — летальность в процентах. Корреляция Спирмена — мера связи между официальными данными и избыточной смертностью. MSE — среднеквадратичная ошибка регрессии.



Описание проведенного исследования

Модель данных. Исходные данные — три плоских таблицы (смертность по годам и месяцам, COVID-статистика, геномная последовательность). После очистки и преобразований формируется основная аналитическая таблица с полями: year, month, death_per_100k (избыточная смертность V2), cases_per_100k (заболеваемость), official_death_per_100k (официальные данные), stamps (доминирующий штамм). Дополнительно созданы агрегированные таблицы: средняя помесечная доковидная смертность (1 строка × 12 месяцев), сводка по штаммам (5 строк, средние death_per_100k, cases_per_100k, CFR), матрица вклада мутаций (14 строк, death_contribution, spread_contribution, composite_contribution).

Преобразования. Нормализация Min-Max для коэффициентов death_coef и spread_coef в шкалу от 1 до 10 для сопоставимости. Приведение всех показателей к единице измерения — на 100 тысяч населения. Агрегация помесечных данных в средние по штаммам. Создание категориальных переменных для штаммов и уровней опасности мутаций (критическая, высокая, средняя, низкая).



Построение модели



4

Построение модели

Задача модели. Проверить, можно ли предсказать избыточную смертность (V_2) на основе официальных данных о смертности от COVID-19, используя линейную регрессию.

Признак. официальная смертность от COVID-19 на 100 тыс. населения.

Целевая переменная. Избыточная смертность V_2 на 100 тыс. населения (разница между фактической и средней доковидной смертностью).

Алгоритм. линейная регрессия. Выбран для проверки гипотезы о линейной связи между показателями.

Оценка качества (LOO-кросс-валидация, 23 точки): $MSE = 260.71$, $R^2 = -0.092$ (отрицательный), коэффициент = 1.60, intercept = 0.40.

Вывод. линейная связь практически отсутствует ($R^2 < 0$). Официальные данные не могут служить линейным предиктором избыточной смертности. Рекомендуются нелинейные модели.



Выводы и рекомендации



5

Выводы и рекомендации

Область внедрения. Методика расчёта избыточной смертности V2 и коэффициенты опасности штаммов могут быть внедрены в систему эпидемиологического мониторинга Департамента здравоохранения Москвы и Роспотребнадзора для оперативной оценки реального влияния новых вариантов вируса.

Результаты внедрения. Разработана и программно реализована методология расчёта избыточной смертности с учётом долгосрочных трендов (V2). Рассчитаны коэффициенты опасности для пяти штаммов: Дельта (2.68), Альфа (2.56), Омикрон (2.34), Nu-1 D614G (1.98), Nu-1 (1.00). Выявлены мутации-маркеры повышенной опасности: N501Y, P681H, P681R. Доказана нелинейность связи между официальными данными и избыточной смертностью ($\rho \approx 0.52$, R^2 отрицательный).

Выводы для стейкхолдеров. Департаменту здравоохранения — официальная статистика занижает реальные потери, избыточная смертность V2 — более объективный индикатор. Роспотребнадзору — штаммы Дельта и Альфа требуют усиленного контроля, Омикрон опасен в основном высокой трансмиссивностью. Минздраву — методику V2 можно рекомендовать как федеральный стандарт оценки влияния эпидемий. Научному сообществу — мутации N501Y, P681H, P681R — приоритетные мишени для исследований. Производителям вакцин — необходимо учитывать эволюцию S-белка, особенно в позициях 501, 681. Населению — реальные риски при заражении Дельтой выше официальных данных в 3.4 раза относительно исходного штамма.

Пути развития. Использовать нелинейные модели (GAM, случайный лес) для предсказания избыточной смертности. Добавить признаки: уровень вакцинации, загруженность больниц, индекс самоизоляции, сезонность. Валидировать методологию на данных других регионов России. Автоматизировать расчёт коэффициентов при появлении новых штаммов. Интегрировать анализ мутаций с реальными данными GISAID для обновления коэффициентов в реальном времени.



Трудности в процессе работы и как их решали



6

Трудности в процессе работы и как их решали

Отрицательные значения в `calculated_death` в исходных данных. Решение: проанализировал методику расчёта, выяснил причину — использована короткая база (2015-2019) без учёта динамики населения. Заменял на собственную методику V2 с базой 2006-2019 и учётом численности населения.



**Спасибо за
внимание!**

